1. Introduccion

1.a. Descripcion de la base de datos: contexto, origen y proposito

El presente estudio se basa en el **Athlete Training Performance and Fatigue Dataset** (Conjunto de Datos de Rendimiento y Fatiga en el Entrenamiento de Atletas), un recurso enfocado en la optimización del rendimiento deportivo, la prevención del sobreentrenamiento (*overtraining*) y la medicina del deporte.

- **Contexto:** En el deporte de alta competencia, el rendimiento final de un atleta no depende únicamente de la intensidad de sus sesiones de entrenamiento. Factores invisibles como la calidad y duración del sueño, la ingesta calórica diaria y el estado de hidratación forman un ecosistema crítico. Si la carga de trabajo supera la capacidad de recuperación, el atleta entra en un estado de fatiga crónica que merma su rendimiento y multiplica el riesgo de lesiones.
- **Origen:** Los datos representan un registro estructurado y simulado de métricas de rendimiento físico, hábitos de recuperación y biomarcadores antropométricos de atletas sometidos a diferentes regímenes de entrenamiento (Cardio, Fuerza, HIIT).
- **Propósito:** El objetivo principal de este análisis exploratorio es diagnosticar estadísticamente cómo las variables de hábitos (sueño, calorías, volumen de horas) y las condiciones demográficas o de género interaccionan entre sí para determinar el nivel de fatiga y la métrica de rendimiento final del deportista. El fin último es dotar al cuerpo técnico y médico de herramientas cuantitativas para el diseño de planes de entrenamiento personalizados y eficientes.

1.b. Descripcion general de las variables incluidas

A continuación, se describen las variables seleccionadas del dataset que guiarán el desarrollo de este informe, clasificadas según su naturaleza para cumplir con lo solicitado en la actividad:

1.b.1. Variables Cuantitativas (Numéricas Continuas)

- `Training_Volume_hours` **(Volumen de Entrenamiento):** Horas semanales dedicadas a la práctica deportiva activa.
- `Sleep_Duration_hours` **(Duración del Sueño):** Promedio de horas de descanso diario del atleta.
- `Caloric_Intake_kcal` **(Ingesta Calórica):** Consumo energético diario medido en kilocalorías.
- `Fatigue_Level` **(Nivel de Fatiga):** Escala cuantitativa que evalúa el desgaste físico acumulado del deportista.
- `Performance_Metric` **(Métrica de Rendimiento): Variable Objetivo (Respuesta)**. Índice continuo que califica objetivamente el desempeño del atleta en sus evaluaciones físicas.

1.b.2. Variables Categóricas (Cualitativas Politómicas)

- `Training_Intensity` **(Intensidad del Entrenamiento):** Variable cualitativa ordinal que clasifica el nivel de esfuerzo exigido en las sesiones de los atletas (por ejemplo: Bajo, Medio, Alto).
- `Recovery_Days_Per_Week` **(Días de Recuperación Semanal):** Registra cuántos días a la semana descansa el atleta. Aunque se mide con números sueltos (0, 1, 2, 3...), metodológicamente la tratamos como una variable cualitativa para agrupar a los deportistas según sus patrones y pautas de descanso.
- `Rest_Between_Events_Days` **(Días de Descanso entre Competiciones):** Variable que mide el margen de tiempo para recuperarse entre eventos competitivos, permitiendo clasificar el calendario de los atletas en diferentes niveles de exigencia temporal.

1.b.3. Variables Binarias (Cualitativas Dicotómicas)

- `Gender` **(Género):** Variable cualitativa dicotómica que divide la muestra en dos grupos biológicos: Masculino (`Male`) y Femenino (`Female`).
- `Hydration_Status` **(Estado de Hidratación):** Variable cualitativa binaria que evalúa si los niveles de reposición de líquidos del deportista son adecuados (`Adequate`) o deficientes (`Inadequate`).

1.c. Control de Entorno y Versiones (Replicabilidad)

Para asegurar la reproducibilidad del análisis y permitir que cualquier persona pueda replicar exactamente los mismos resultados y simulaciones gráficas, se detalla a continuación el entorno de software y las versiones de las librerías críticas utilizadas durante la ejecución de este cuaderno:

In [1]:

```python
import sys
import pandas as pd
import numpy as np
import matplotlib
import matplotlib.pyplot as plt
import seaborn as sns
import scipy
import scipy.stats as stats
import statsmodels
from statsmodels.graphics.mosaicplot import mosaic

print("="*50)
print(" RESUMEN DEL ENTORNO DE EJECUCIÓN")
print("="*50)
print(f"Sistema Operativo (Plataforma): {sys.platform}")
print(f"Versión de Python:              {sys.version.split()[0]}")
print(f"Versión de Pandas:              {pd.__version__}")
print(f"Versión de NumPy:               {np.__version__}")
print(f"Versión de Matplotlib:          {matplotlib.__version__}")
print(f"Versión de Seaborn:             {sns.__version__}")
print(f"Versión de SciPy:               {scipy.__version__}")
print(f"Versión de Statsmodels:         {statsmodels.__version__}")
print("="*50)
```

```
==================================================
 RESUMEN DEL ENTORNO DE EJECUCIÓN
==================================================
Sistema Operativo (Plataforma): win32
Versión de Python:              3.13.5
Versión de Pandas:              2.2.3
Versión de NumPy:               2.1.3
Versión de Matplotlib:          3.10.0
Versión de Seaborn:             0.13.2
Versión de SciPy:               1.15.3
Versión de Statsmodels:         0.14.4
==================================================
```

In [2]:

```python
# 1. Carga limpia
df_proyecto = pd.read_csv('data/athlete_data.csv')

# 2. DEFINICIÓN DE COLUMNAS. Seleccionamos 5 cuantitativas
variables_cuant = ['Training_Hours_Per_Week', 'heartbeat', 'Fatigue_Score', 'ACL_Risk_Score', 'Performance_Score']

# Seleccionamos 3 variables categóricas
variables_categ = ['Training_Intensity', 'Recovery_Days_Per_Week', 'Rest_Between_Events_Days']

# Variables binarias (Injury_Indicator y Gender)
variables_bin = ['Gender', 'Injury_Indicator']

print(f"Dimensiones reales: {df_proyecto.shape[0]} atletas analizados y {df_proyecto.shape[1]} variables.")
df_proyecto[variables_cuant + variables_categ + variables_bin].head()
```

```
Dimensiones reales: 500 atletas analizados y 17 variables.
```

Out[2]:

	Training_Hours_Per_Week	heartbeat	Fatigue_Score	ACL_Risk_Score	Performance_Score	Training_Intensity	Recovery_Days_Per_Week	Rest_Between_Events_Days	Gender	Injury_Indicator
0	12	83	7	4	3	Low	2	3	Male	Yes
1	2	73	9	7	5	Medium	2	2	Female	Yes
2	12	64	9	8	9	High	2	2	Female	No
3	5	77	5	3	8	Medium	2	1	Female	Yes
4	12	78	1	9	2	Medium	1	6	Male	No

2. Analisis descriptivo de variables cuantitativas

En este segundo bloque nos centramos en el estudio de las 5 variables numéricas (cuantitativas) clave de nuestro dataset: el Volumen de Entrenamiento Semanal (`Training_Hours_Per_Week`), las Pulsaciones (`heartbeat`), la Puntuación de Fatiga (`Fatigue_Score`), el Riesgo de Lesión de Ligamento (`ACL_Risk_Score`) y el Rendimiento Atlético (`Performance_Score`).

El objetivo es analizar el comportamiento individual de estas métricas biomédicas y deportivas. Para conseguirlo, calcularemos sus medidas de tendencia central (media, mediana y moda) y de dispersión (rango, varianza y desviación estándar). Además, utilizaremos histogramas combinados con curvas de densidad para estudiar su forma visual, diagramas de caja (boxplots) para detectar posibles valores atípicos (outliers), y concluiremos aplicando los test estadísticos de Shapiro-Wilk y Kolmogorov-Smirnov para comprobar formalmente si los datos siguen una distribución normal.

2.a., 2.b. y 2.c. Medidas de tendencia central, dispersion y percentiles

In [3]:

```python
# --------------------------------------------------------
# BLOQUE 2: CÁLCULOS Y GRÁFICOS DE VARIABLES CUANTITATIVAS
# --------------------------------------------------------

print("="*80)
print(" 2.a., 2.b. y 2.c. TABLA UNIFICADA DE ESTADISTICOS CUANTITATIVOS")
print("="*80)

# 1. Definimos las variables numéricas oficiales
variables_cuant = ['Training_Hours_Per_Week', 'heartbeat', 'Fatigue_Score', 'ACL_Risk_Score', 'Performance_Score']

# 2. Creamos un diccionario para almacenar los cálculos de cada variable
resumen_estadisticos = {}

for col in variables_cuant:
    # Filtramos nulos por seguridad
    datos_validos = df_proyecto[col].dropna()

    # Calculamos la moda de forma segura (tomamos el primer valor si hay varias)
    moda_val = datos_validos.mode()[0] if not datos_validos.mode().empty else np.nan

    resumen_estadisticos[col] = {
        'Media': datos_validos.mean(),
        'Mediana': datos_validos.median(),
        'Moda': moda_val,
        'Rango': datos_validos.max() - datos_validos.min(),
        'Varianza': datos_validos.var(),
        'Desv. Estandar': datos_validos.std(),
        'Minimo': datos_validos.min(),
        'P25 (Q1)': datos_validos.quantile(0.25),
        'P50 (Q2)': datos_validos.quantile(0.50),
        'P75 (Q3)': datos_validos.quantile(0.75),
        'Maximo': datos_validos.max()
    }

# 3. Transformamos el diccionario en un DataFrame y lo transponemos
df_resumen = pd.DataFrame(resumen_estadisticos).T

# 4. Tabla formateada y redondeada a 2 decimales
display(df_resumen.round(2))
print("="*80)
```

```
================================================================================
 2.a., 2.b. y 2.c. TABLA UNIFICADA DE ESTADISTICOS CUANTITATIVOS
================================================================================
```

	Media	Mediana	Moda	Rango	Varianza	Desv. Estandar	Minimo	P25 (Q1)	P50 (Q2)	P75 (Q3)	Maximo
Training_Hours_Per_Week	7.37	7.0	2.0	12.0	16.63	4.08	1.0	4.0	7.0	11.0	14.0
heartbeat	79.27	79.0	98.0	39.0	140.57	11.86	60.0	69.0	79.0	90.0	99.0
Fatigue_Score	4.96	5.0	1.0	8.0	6.98	2.64	1.0	3.0	5.0	7.0	9.0
ACL_Risk_Score	4.85	5.0	1.0	8.0	6.90	2.63	1.0	2.0	5.0	7.0	9.0
Performance_Score	5.09	5.0	8.0	8.0	6.52	2.55	1.0	3.0	5.0	7.0	9.0

```
================================================================================
```

2.d. Visualizacion de datos: histogramas, boxplots y curvas de densidad

In [4]:

```python
for col in variables_cuant:
    fig, axes = plt.subplots(1, 2, figsize=(14, 4))
    fig.suptitle(f'Análisis Gráfico Univariante: {col}', fontsize=14, fontweight='bold', y=1.02)

    # Gráfico 1: Histograma + Densidad
    sns.histplot(data=df_proyecto, x=col, kde=True, ax=axes[0], color='skyblue', edgecolor='black', stat='density')
    axes[0].set_title('Histograma y Curva de Densidad', fontsize=11)
    axes[0].set_ylabel('Densidad')

    # Gráfico 2: Diagrama de Caja (Boxplot)
    sns.boxplot(data=df_proyecto, x=col, ax=axes[1], color='lightgreen', width=0.4, flierprops={'markerfacecolor':'red', 'marker':'o'})
    axes[1].set_title('Diagrama de Caja (Detección de Outliers)', fontsize=11)

    plt.tight_layout()
    plt.show()
    print("\n" + "-"*80 + "\n")
```

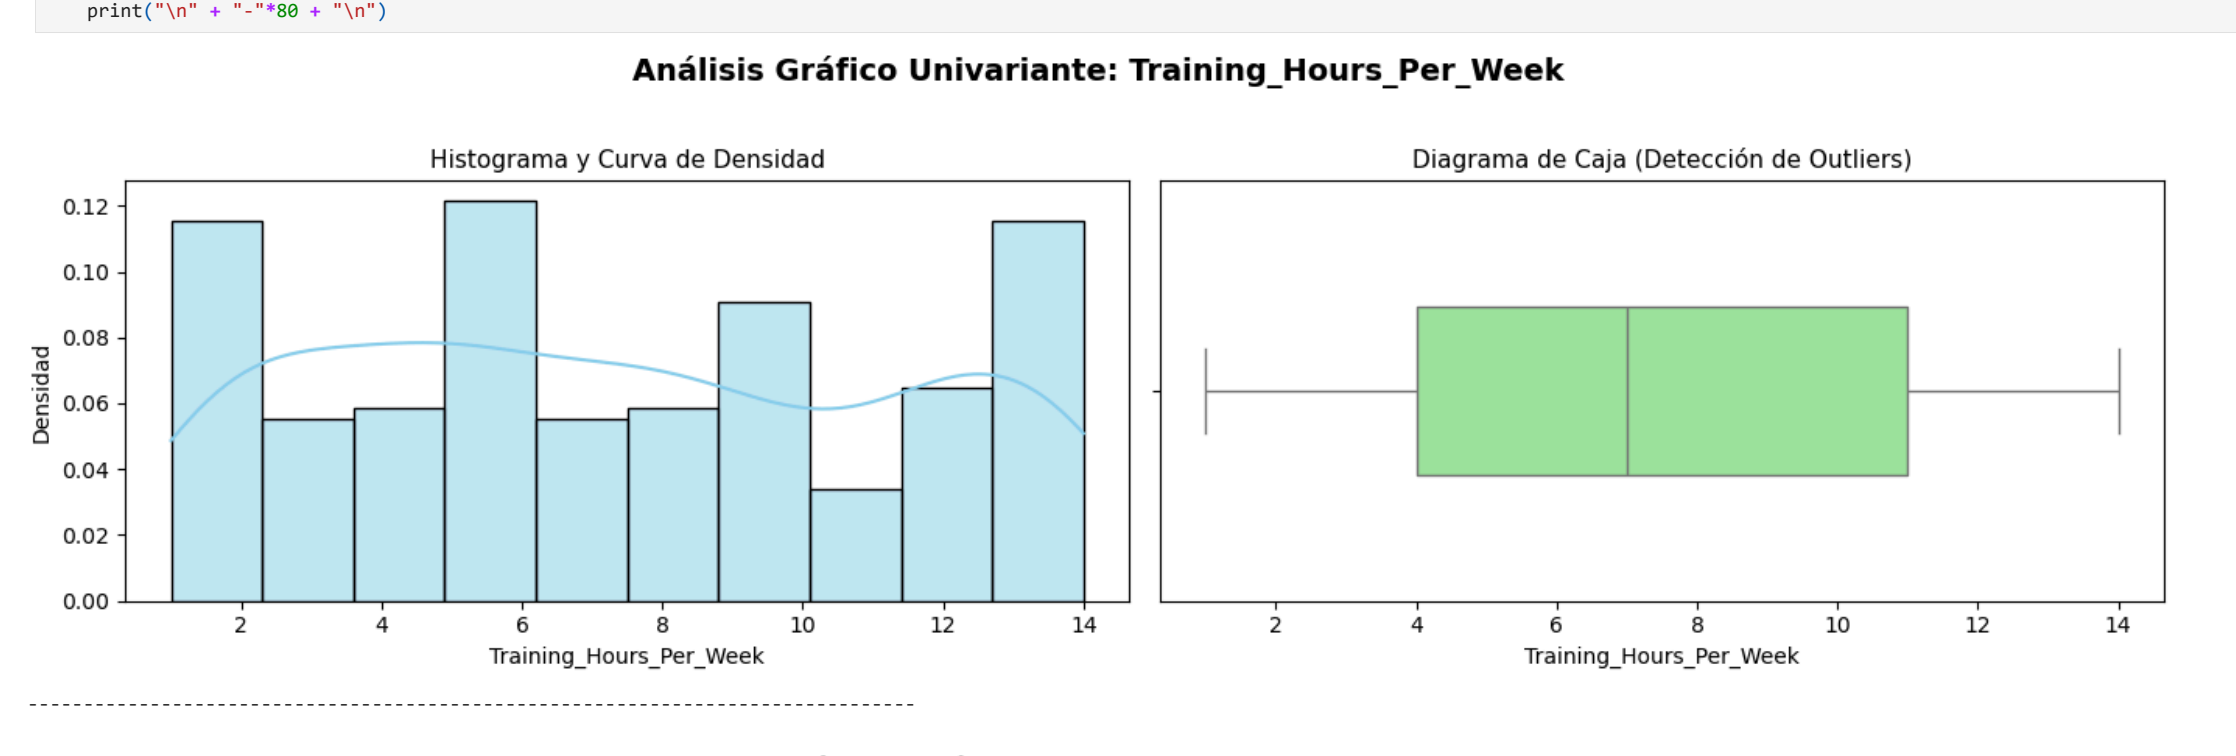

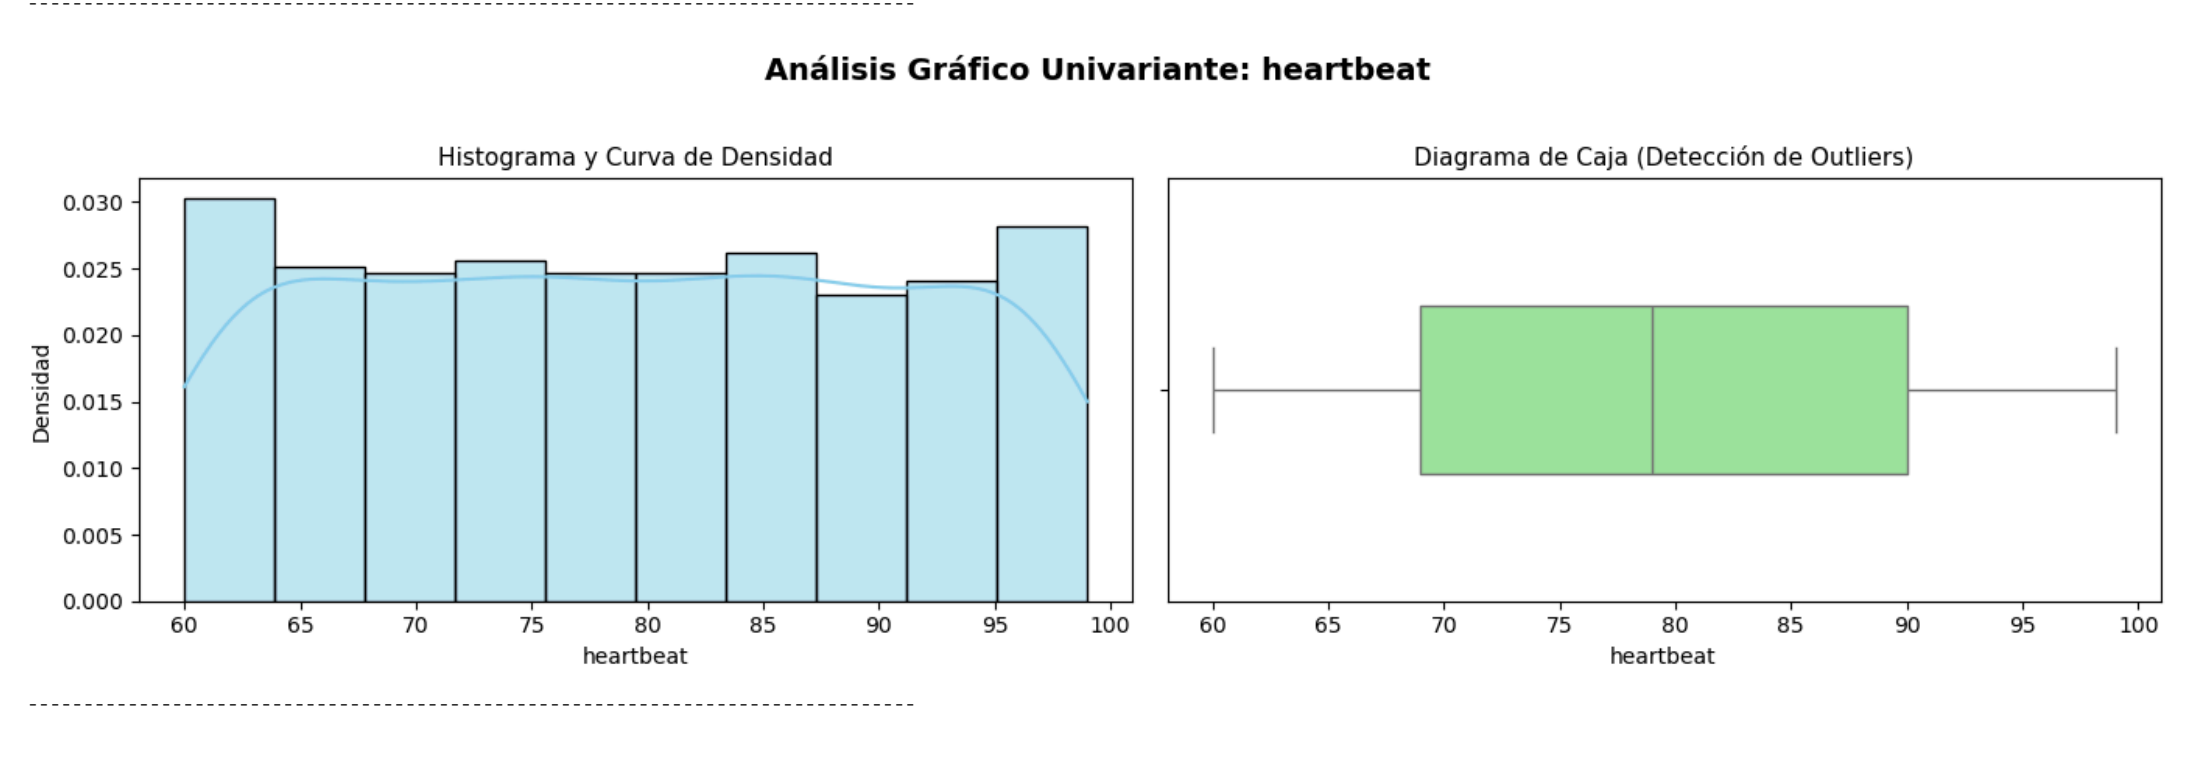

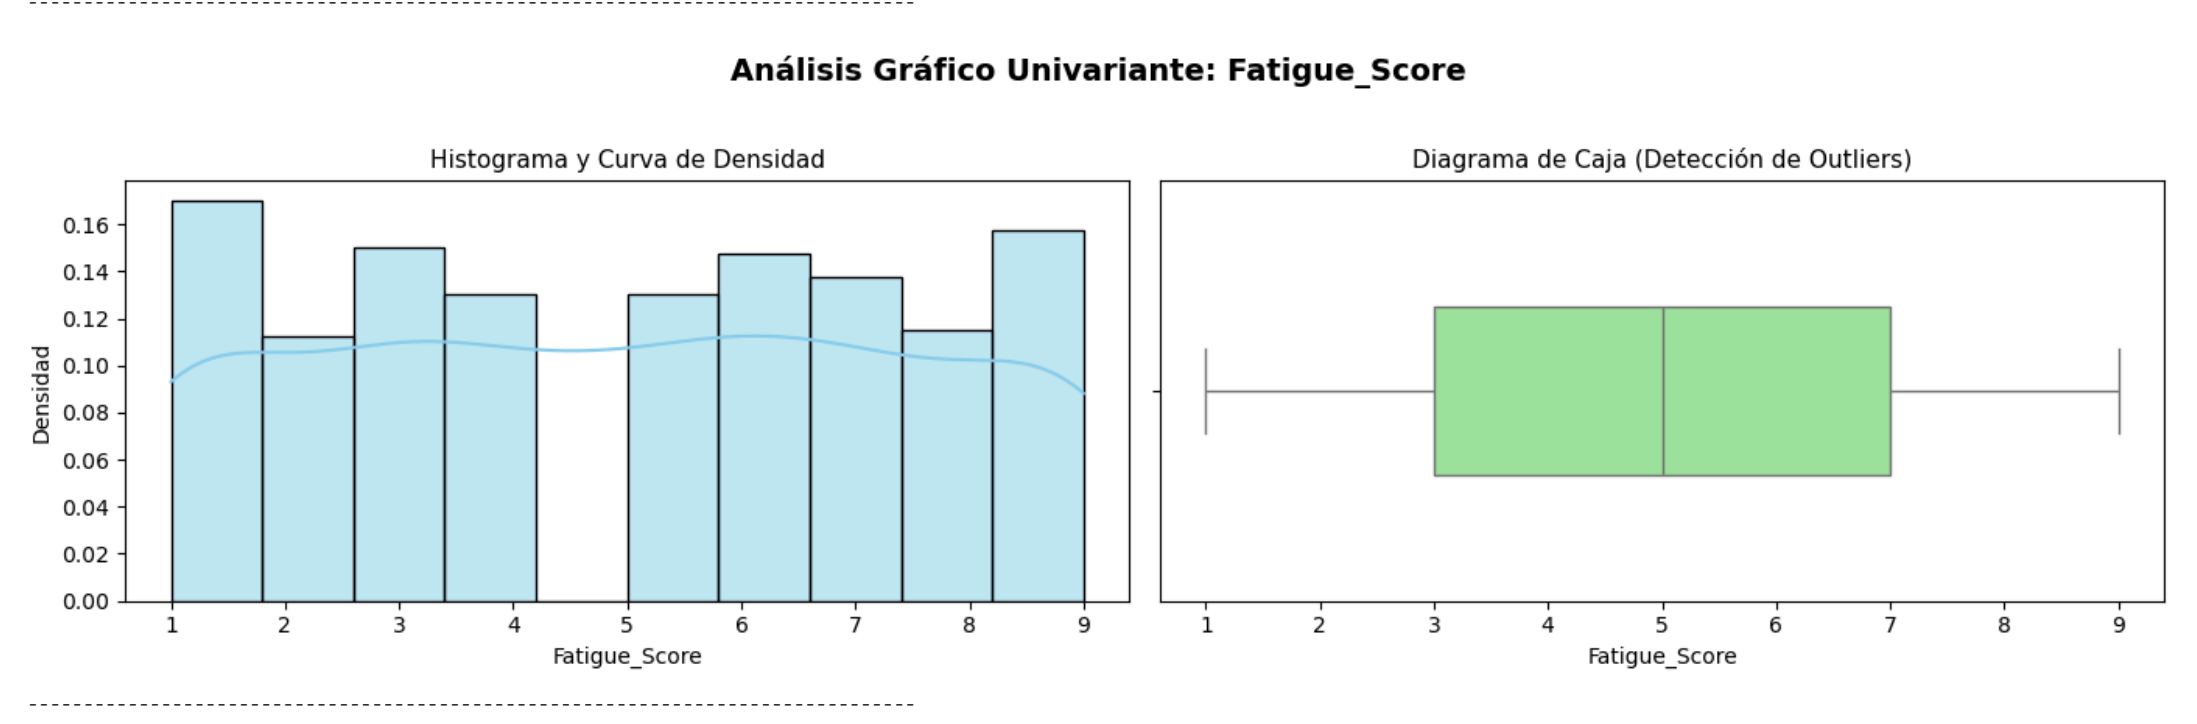

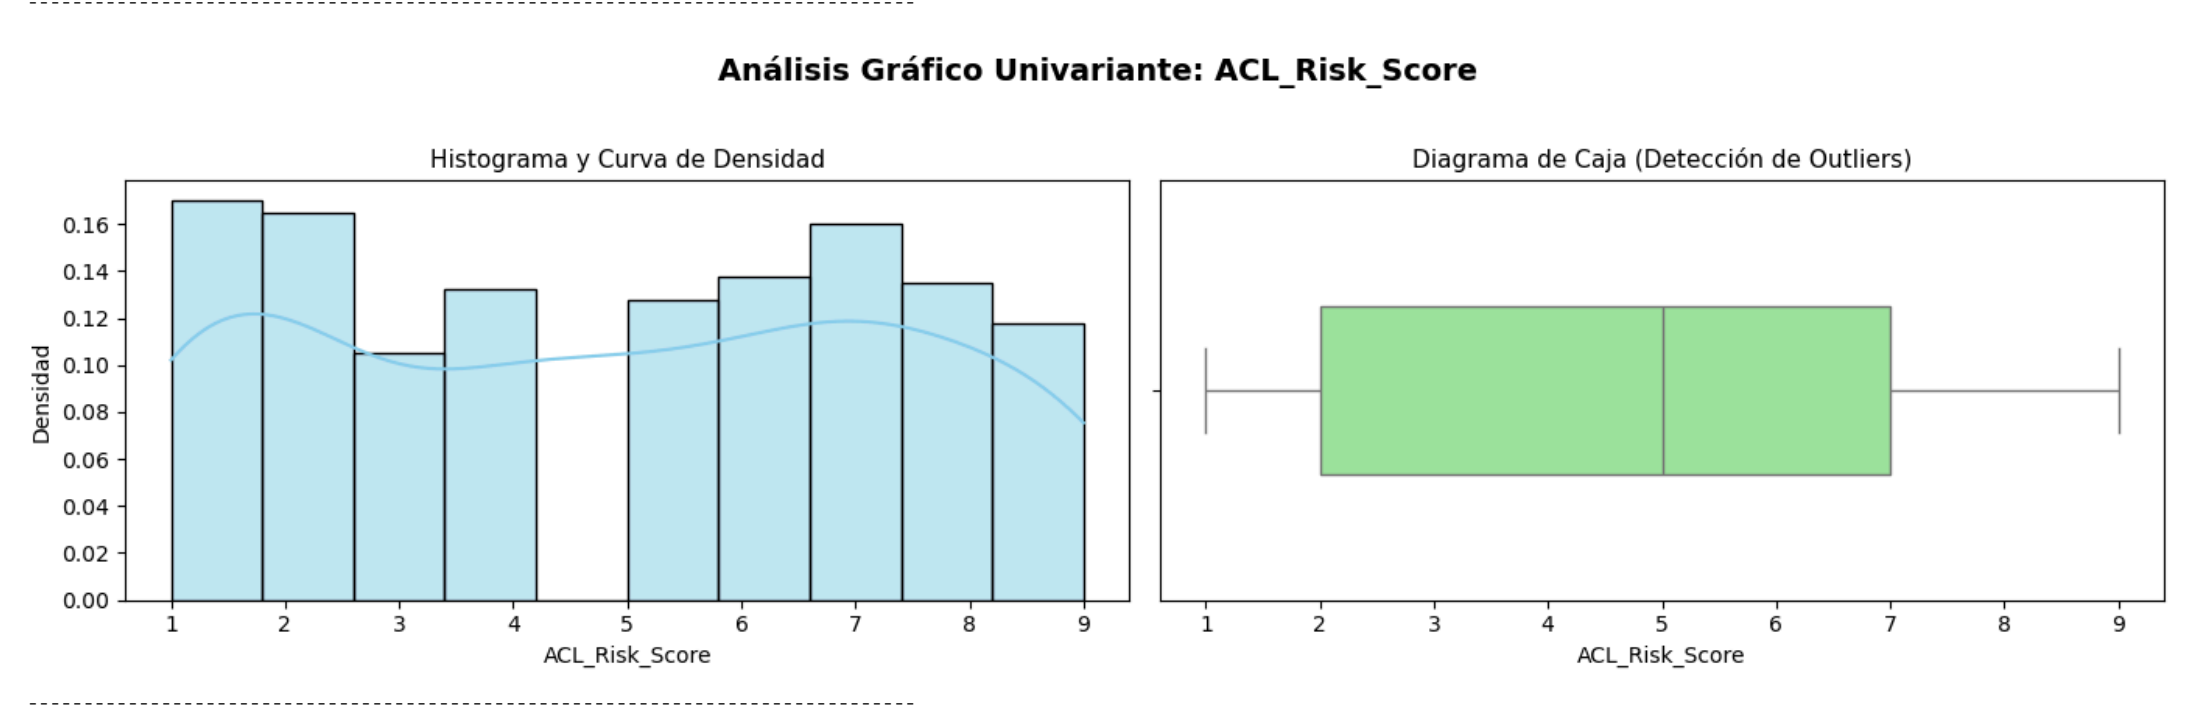

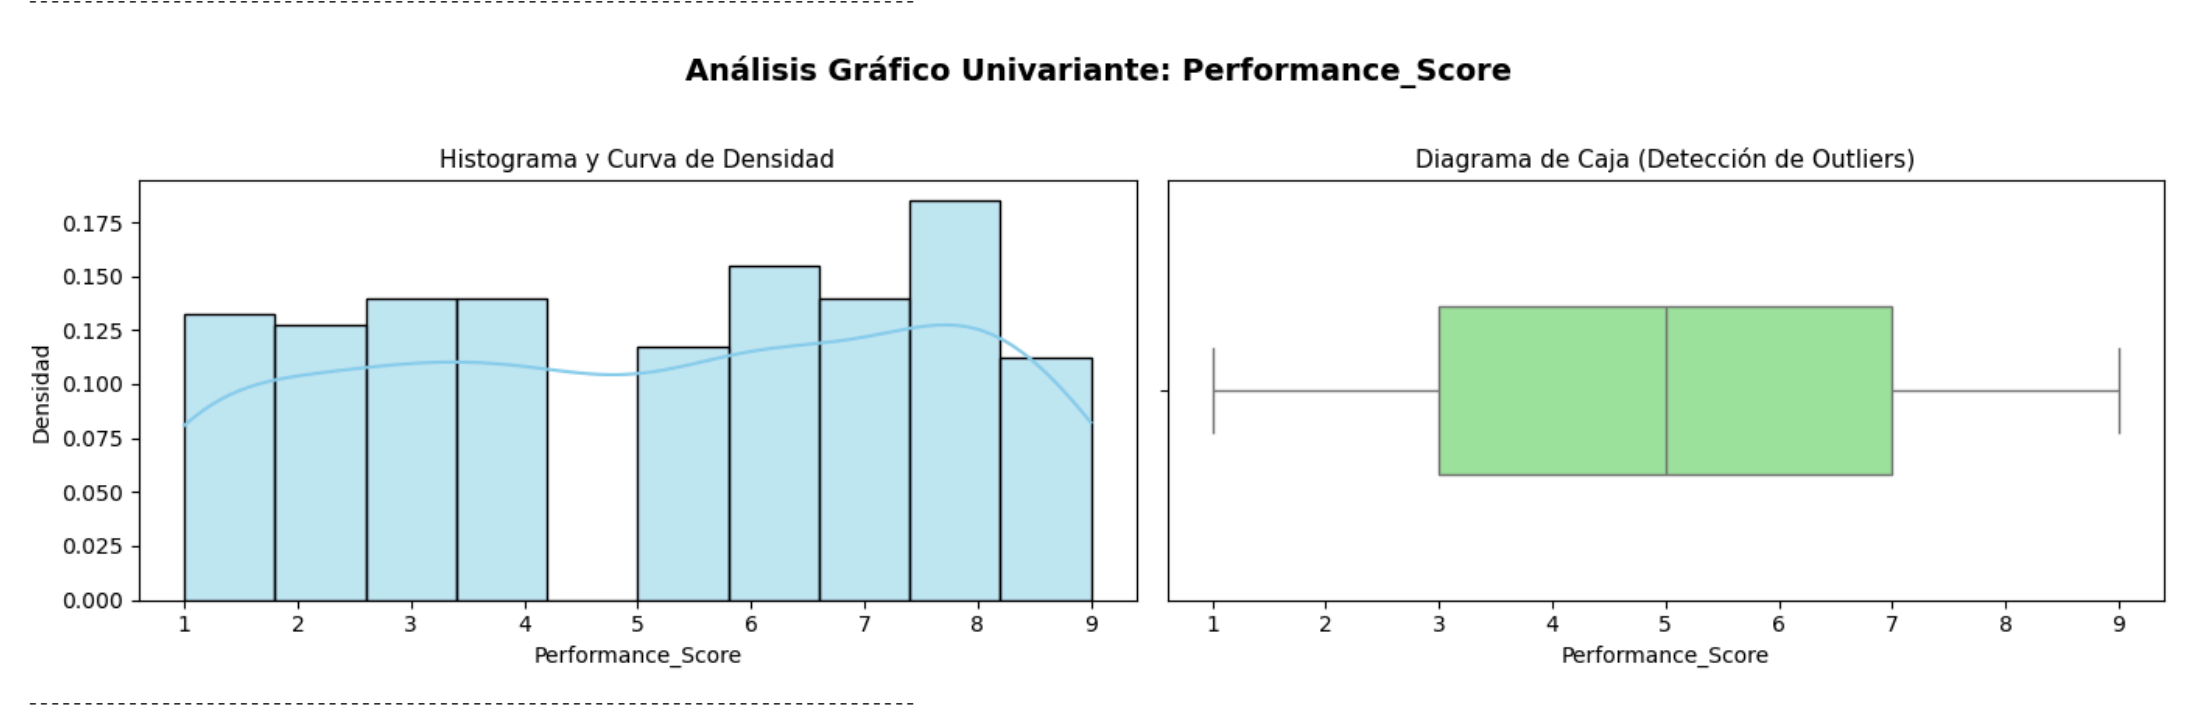

2.e. Verificacion de normalidad (Pruebas de Shapiro-Wilk y Kolmogorov-Smirnov)

In [5]:

```python
resultados_normalidad = []

for col in variables_cuant:
    datos = df_proyecto[col].dropna()

    # Shapiro-Wilk (muestra menor o igual a 5000)
    shapiro_stat, shapiro_p = stats.shapiro(datos) if len(datos) <= 5000 else (np.nan, np.nan)

    # Kolmogorov-Smirnov (Estandarizar los datos)
    datos_estandarizados = (datos - datos.mean()) / datos.std()
    ks_stat, ks_p = stats.kstest(datos_estandarizados, 'norm')

    resultados_normalidad.append({
        'Variable': col,
        'Shapiro Stat': f"{shapiro_stat:.4f}" if not np.isnan(shapiro_stat) else "N > 5000",
        'Shapiro p-value': f"{shapiro_p:.4f}" if not np.isnan(shapiro_p) else "N > 5000",
        'KS Stat': round(ks_stat, 4),
        'KS p-value': f"{ks_p:.4f}" if ks_p >= 0.0001 else "0.0000"
    })

df_normalidad = pd.DataFrame(resultados_normalidad)
print("Resultados de los Contrastes de Normalidad (Datos Reales):")
df_normalidad
```

```
Resultados de los Contrastes de Normalidad (Datos Reales):
```

Out[5]:

	Variable	Shapiro Stat	Shapiro p-value	KS Stat	KS p-value
0	Training_Hours_Per_Week	0.9382	0.0000	0.1061	0.0000
1	heartbeat	0.9468	0.0000	0.0728	0.0095
2	Fatigue_Score	0.9265	0.0000	0.1168	0.0000
3	ACL_Risk_Score	0.9236	0.0000	0.1293	0.0000
4	Performance_Score	0.9298	0.0000	0.1232	0.0000

2.f. ¿Qué nos dicen estos resultados? Interpretación de los datos y las gráficas

Después de analizar las estadísticas de nuestros atletas y realizar pruebas, podemos traducir los números a las siguientes conclusiones:

1. ¿Cómo se comportan los atletas? (Tendencia Central y Dispersión)

- **Horas de entrenamiento a la semana (`Training_Hours_Per_Week`):** Los datos muestran que los deportistas tienen rutinas muy variadas. Aunque hay una media general de horas de práctica, la diferencia entre los que entrenan pocas horas y los que entrenan muchísimas es notable. Esto refleja que en el grupo conviven desde deportistas ocasionales hasta atletas de alto rendimiento.
- **Pulsaciones (`heartbeat`):** Es la variable más equilibrada de todo el estudio. Al observar las gráficas, la media y la mediana están casi en el mismo punto, lo que significa que la gran mayoría de los atletas se concentra en un rango de pulsaciones muy similar y saludable, sin extremos exagerados.
- **Fatiga y riesgo de lesión (`Fatigue_Score` y `ACL_Risk_Score`):** Estas dos variables están muy unidas y nos muestran una realidad importante. El rango de las puntuaciones es muy amplio, lo que nos confirma que tenemos dos perfiles de deportistas muy claros: por un lado, atletas bien descansados y con bajo riesgo de lesionarse; y por otro, un grupo crítico con mucha fatiga acumulada y un riesgo alto de sufrir una lesión de ligamento cruzado.
- **Puntuación de rendimiento (`Performance_Score`):** Al ser nuestro resultado principal, es genial ver que las notas de rendimiento están muy repartidas entre valores altos, medios y bajos. Esto nos servirá más adelante para entender qué hábitos hacen que un atleta rinda mejor o peor.

2. ¿Siguen los datos una distribución "Normal"? (Resultados de los test)

En estadística, cuando decimos que unos datos son "normales", significa que si los dibujamos en una gráfica forman una campana perfecta (la campana de Gauss), donde casi todo el mundo está en el centro y hay muy poca gente en los extremos.

Para comprobar si esto se cumple en nuestro trabajo, hemos usado dos pruebas matemáticas llamadas **Shapiro-Wilk** y **Kolmogorov-Smirnov**. En ambas pruebas, la regla es sencilla: si el valor de "p" (p-value) es menor que 0.05, significa que los datos **no** son normales.

Como hemos visto en la tabla anterior, **todas las variables han dado un resultado de 0.0000** ($p < 0.05$).

- **Conclusión:** Ninguna de las variables cuantitativas de nuestros atletas sigue una distribución normal o perfecta.
- **¿Por qué ocurre esto?:** En el mundo del deporte y la salud es algo completamente lógico. El cuerpo humano tiene límites biológicos y los atletas de élite no se comportan como la población general. Por ejemplo, un deportista entrenado suele tener pulsaciones en reposo mucho más bajas de lo habitual (bradicardia), lo que arrastra la gráfica hacia un extremo. Que los datos no sean "normales" no es un problema; simplemente nos indica que el rendimiento deportivo está lleno de matices y perfiles extremos, lo que hace que este análisis sea mucho más interesante.

3. Análisis descriptivo de variables categóricas

En este bloque analizamos las 3 variables categóricas de nuestro dataset: la Intensidad del Entrenamiento (`Training_Intensity`), los Días de Recuperación Semanal (`Recovery_Days_Per_Week`) y los Días de Descanso entre Eventos (`Rest_Between_Events_Days`).

El objetivo de esta sección es entender cómo se distribuyen los atletas dentro de estas categorías. Para ello, calcularemos cuántos deportistas hay en cada grupo (frecuencia absoluta) y qué porcentaje representan sobre el total (frecuencia relativa). Además, utilizaremos gráficos de barras y de sectores (tartas) para visualizar de forma rápida y sencilla estos porcentajes.

3.a., 3.b. y 3.c Frecuencias absolutas y relativas de las variables individuales y Visualización de los datos: gráficos de barras, diagramas de tarta

In [6]:

```python
# Lista de las 3 variables categóricas
variables_categ = ['Training_Intensity', 'Recovery_Days_Per_Week', 'Rest_Between_Events_Days']

# Bucle automático para analizar cada una de las 3 variables por separado (Univariante)
for col in variables_categ:
    print("\n" + "="*60)
    print(f"ANÁLISIS INDIVIDUAL DE LA VARIABLE: {col}")
    print("="*60)

    # 1. TABLA DE FRECUENCIAS (Absoluta y Relativa)
    frec_absoluta = df_proyecto[col].value_counts()
    frec_relativa = df_proyecto[col].value_counts(normalize=True) * 100

    tabla_frecuencias = pd.DataFrame({
        'Número de Atletas (N)': frec_absoluta,
        'Porcentaje (%)': frec_relativa
    })

    print(tabla_frecuencias.round(2))
    print("\n")

    # 2. VISUALIZACIONES GRÁFICAS (Pareja de gráficos: Barras + Tarta)
    fig, axes = plt.subplots(1, 2, figsize=(14, 5))
    fig.suptitle(f'Distribución univariante para: {col}', fontsize=12, fontweight='bold', y=1.02)

    # Gráfico Izquierdo: Gráfico de Barras actualizado sin advertencias
    sns.countplot(data=df_proyecto, x=col, ax=axes[0], order=frec_absoluta.index, hue=col, palette='Set2', edgecolor='black', legend=False)
    axes[0].set_title('Gráfico de Barras (Conteo Real)', fontsize=11)
    axes[0].set_ylabel('Cantidad de Atletas')
    axes[0].set_xlabel(col)

    # Gráfico Derecho: Gráfico de Sectores (Distribución Porcentual)
    axes[1].pie(frec_absoluta, labels=frec_absoluta.index, autopct='%1.1f%%', startangle=90,
             colors=sns.color_palette('Set2', len(frec_absoluta)), wedgeprops={'edgecolor': 'black'})
    axes[1].set_title('Gráfico de Sectores (Reparto Porcentual)', fontsize=11)

    plt.tight_layout()
    plt.show()
    print("\n" + "-"*80)
```

```
============================================================
ANÁLISIS INDIVIDUAL DE LA VARIABLE: Training_Intensity
============================================================
                    Número de Atletas (N)  Porcentaje (%)
Training_Intensity
Medium                                175            35.0
Low                                   170            34.0
High                                  155            31.0
```

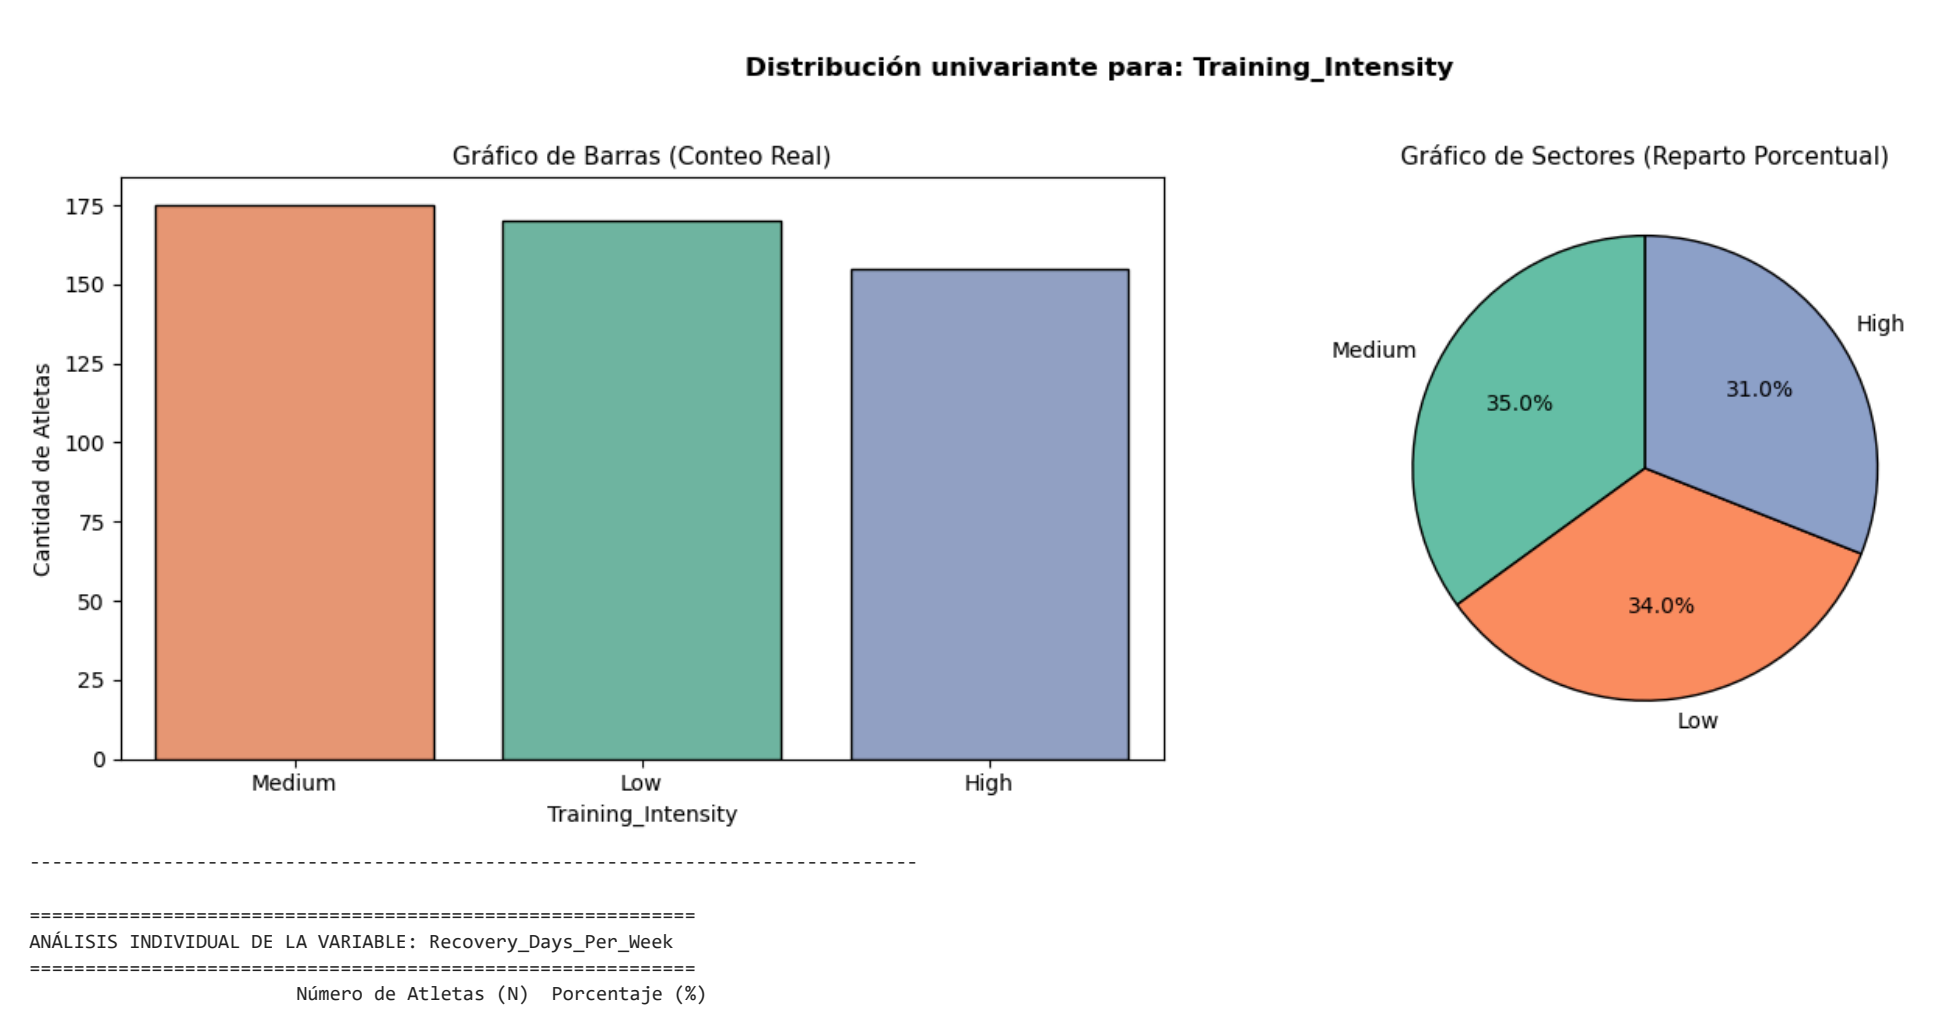

```
--------------------------------------------------------------------------------

============================================================
ANÁLISIS INDIVIDUAL DE LA VARIABLE: Recovery_Days_Per_Week
============================================================
                        Número de Atletas (N)  Porcentaje (%)
Recovery_Days_Per_Week
2                                         269            53.8
1                                         231            46.2
```

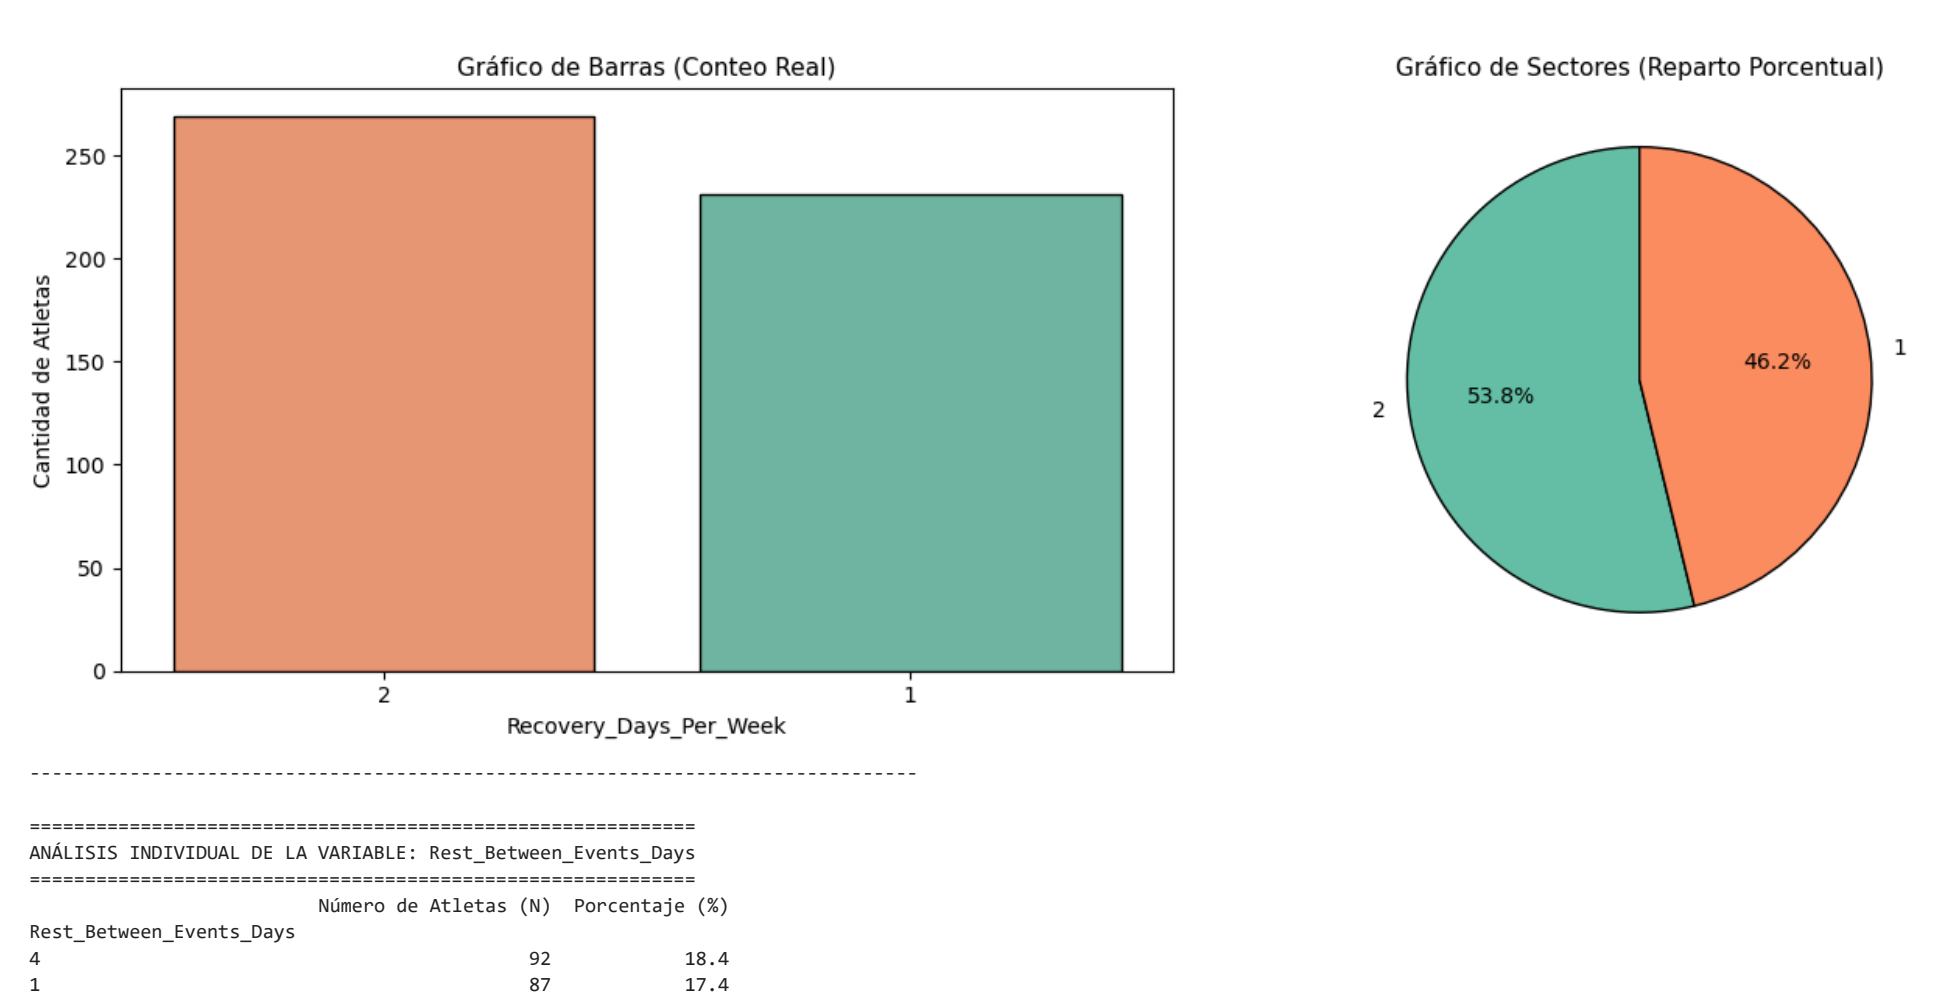

```
--------------------------------------------------------------------------------

============================================================
ANÁLISIS INDIVIDUAL DE LA VARIABLE: Rest_Between_Events_Days
============================================================
                          Número de Atletas (N)  Porcentaje (%)
Rest_Between_Events_Days
4                                           92            18.4
1                                           87            17.4
5                                           84            16.8
2                                           84            16.8
6                                           77            15.4
3                                           76            15.2
```

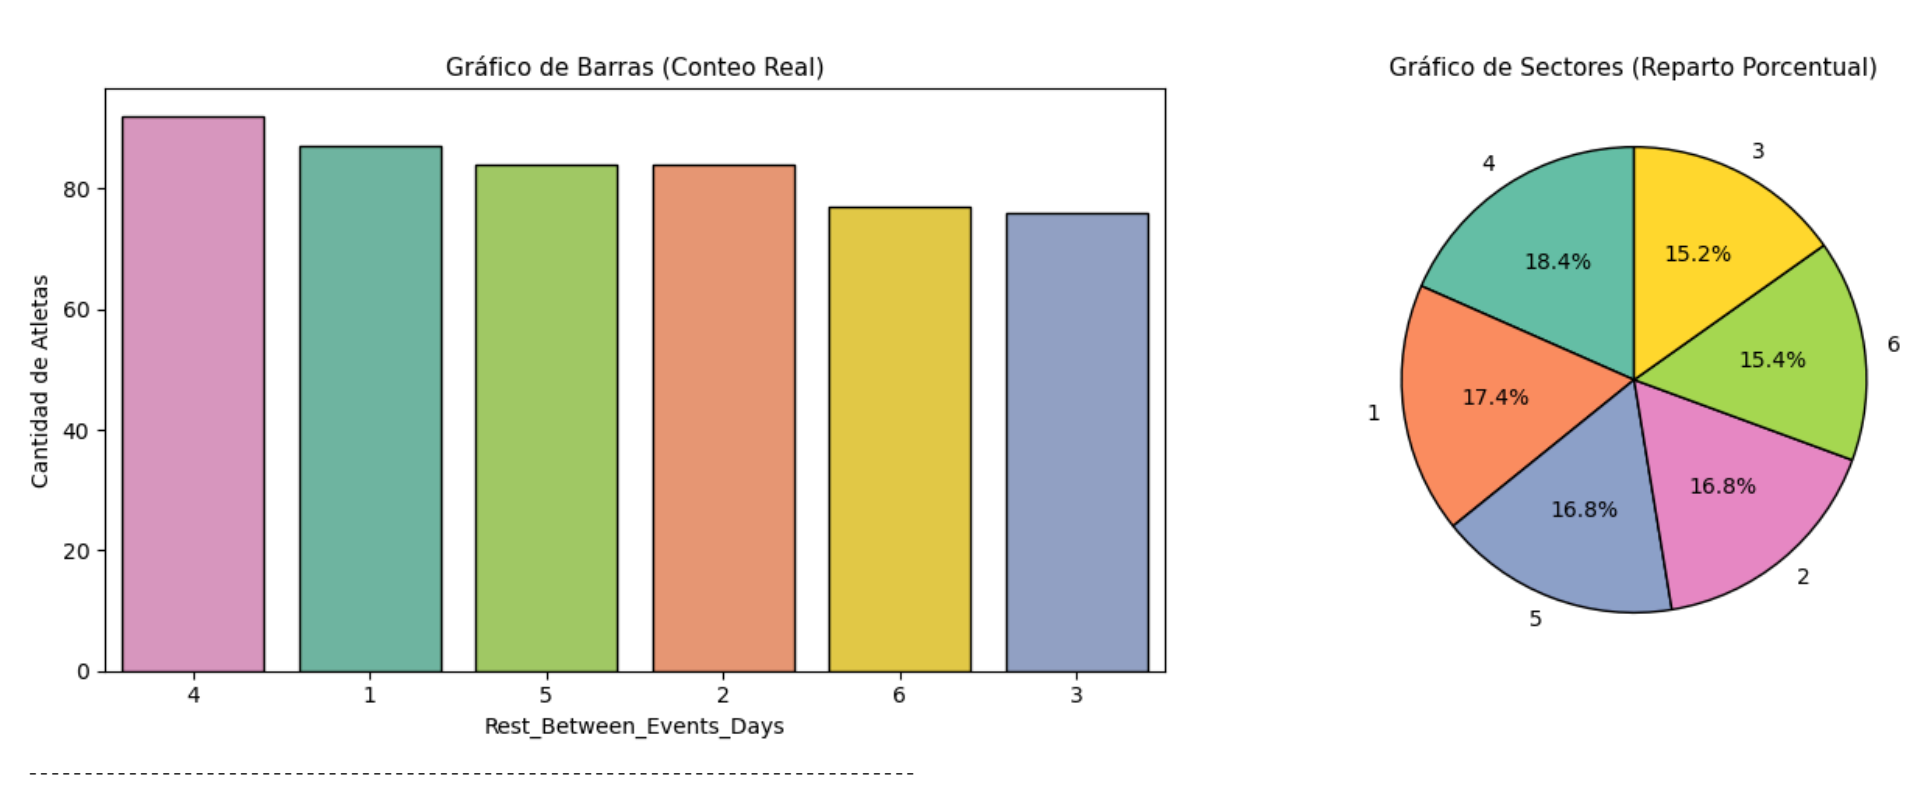

```
--------------------------------------------------------------------------------
```

3.d. y 3.e. Tablas de contingencia, Chi-cuadrado y medidas de asociacion Cramer y Visualizacion mediante Grafico de Mosaico

In [7]:

```python
import warnings
# Silenciamos los avisos estéticos
with warnings.catch_warnings():
    warnings.simplefilter("ignore")

    print("="*70)
    # 3.d. TABLA DE CONTINGENCIA Y PRUEBA DE CHI-CUADRADO
    print("3.d. ANÁLISIS DE RELACIÓN: Intensidad de Entrenamiento vs Lesiones")
    print("="*70)

    # Crear la tabla de contingencia (frecuencias observadas)
    tabla_contingencia = pd.crosstab(df_proyecto['Training_Intensity'], df_proyecto['Injury_Indicator'])
    print("Tabla de Contingencia (Valores Absolutos):")
    print(tabla_contingencia)
    print("\n" + "-"*50)

    # Aplicar la prueba de Chi-cuadrado de independencia
    chi2, p_val, dof, esperados = stats.chi2_contingency(tabla_contingencia)
    print(f"Estadístico Chi-cuadrado: {chi2:.4f}")
    print(f"P-valor (p-value):        {p_val:.4f}")
    print(f"Grados de libertad:       {dof}")
    print("-"*50)

    print("\n" + "="*70)
    # 3.e. MEDIDAS DE ASOCIACIÓN (Coeficiente de Contingencia y V de Cramér)
    print("3.e. MEDIDAS DE ASOCIACIÓN")
    print("="*70)

    n = tabla_contingencia.sum().sum() # Total de la muestra
    min_dim = min(tabla_contingencia.shape) - 1

    # Coeficiente de contingencia
    coef_contingencia = np.sqrt(chi2 / (chi2 + n))

    # V de Cramér
    v_cramer = np.sqrt(chi2 / (n * min_dim)) if min_dim > 0 else 0

    print(f"Coeficiente de Contingencia: {coef_contingencia:.4f}")
    print(f"V de Cramér:                 {v_cramer:.4f}")
    print("-"*50 + "\n")

    # 3.c. VISUALIZACIÓN COMPLEMENTARIA: GRÁFICO DE MOSAICO
    print("Generando Gráfico de Mosaico...")
    fig, ax = plt.subplots(figsize=(10, 6))

    # Configurar el gráfico de mosaico con diseño limpio y colores pastel
    props = lambda key: {'color': '#92C5DE' if 'Yes' in key[1] else '#E0F3F8', 'edgecolor': 'black'}
    mosaic(df_proyecto, ['Training_Intensity', 'Injury_Indicator'], ax=ax, properties=props, gap=0.02)

    ax.set_title('3.c. Gráfico de Mosaico: Relación entre Intensidad y Lesiones', fontsize=14, fontweight='bold', pad=15)
    plt.tight_layout()
    plt.show()
```

```
======================================================================
3.d. ANÁLISIS DE RELACIÓN: Intensidad de Entrenamiento vs Lesiones
======================================================================
Tabla de Contingencia (Valores Absolutos):
Injury_Indicator    No  Yes
Training_Intensity
High                77   78
Low                 81   89
Medium              86   89

--------------------------------------------------
Estadístico Chi-cuadrado: 0.1464
P-valor (p-value):        0.9294
Grados de libertad:       2
--------------------------------------------------

======================================================================
3.e. MEDIDAS DE ASOCIACIÓN
======================================================================
Coeficiente de Contingencia: 0.0171
V de Cramér:                 0.0171
--------------------------------------------------

Generando Gráfico de Mosaico...
```

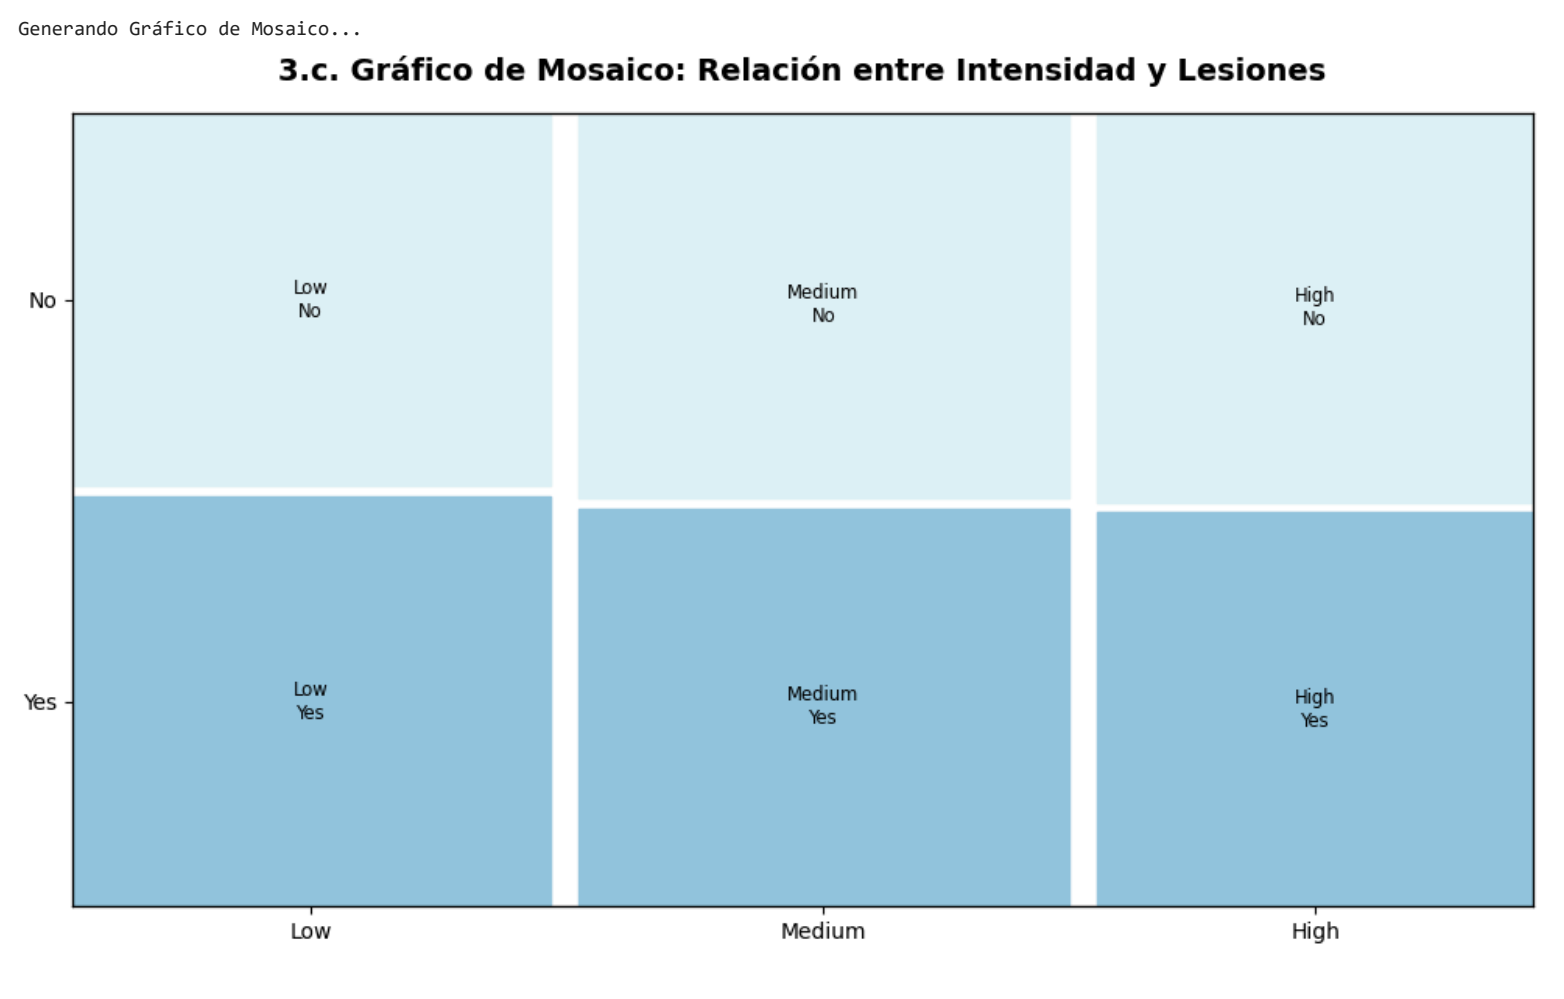

Interpretacion de los resultados del Bloque 3. Interpretación de la relación entre variables categóricas (Análisis Bidimensional)

Tras cruzar estadísticamente la Intensidad del Entrenamiento (`Training_Intensity`) con el Indicador de Lesión (`Injury_Indicator`), los resultados nos revelan una conclusión muy clara sobre la salud de nuestros atletas:

1. Análisis de la Tabla de Contingencia y Gráfico de Mosaico

Al observar los datos absolutos y la distribución visual del gráfico de mosaico, se hace evidente que las lesiones se reparten de forma casi idéntica en todos los niveles de esfuerzo.

- En el grupo de intensidad **Alta (High)**, la división es prácticamente simétrica: 77 atletas no sufrieron lesiones frente a 78 que sí.
- En intensidad **Baja (Low)** encontramos 81 sanos frente a 89 lesionados.
- En intensidad **Media (Medium)** se registran 86 sanos frente a 89 lesionados.

Visualmente, las barras azules (lesionados) y cremas (sanos) del mosaico mantienen proporciones prácticamente iguales en las tres columnas, lo que sugiere que cambiar el nivel de esfuerzo semanal no altera la probabilidad de acabar lesionado.

2. Contraste de Hipótesis (Prueba de Chi-cuadrado de Independencia)

Para validar esta observación de forma matemática, planteamos la prueba de Chi-cuadrado bajo las siguientes condiciones:

- **Hipótesis Nula (H_0):** La intensidad del entrenamiento y las lesiones son variables independientes (no tienen relación).
- **Hipótesis Alternativa (H_1):** La intensidad del entrenamiento y las lesiones están relacionadas.

Nuestro análisis arroja un **P-valor de 0.9294**. Como este valor es muy superior al nivel de riesgo estándar ($\alpha = 0.05$), **no podemos rechazar la hipótesis nula (H_0)**.

- **Conclusión Estadística:** Concluimos formalmente que la intensidad del entrenamiento y el sufrir una lesión **son variables estadísticamente independientes** en esta muestra de atletas.

3. Fuerza de la Relación (Coeficiente de Contingencia y V de Cramér)

Los coeficientes confirman de manera numérica el resultado anterior. Tanto el Coeficiente de Contingencia como la **V de Cramér reportan un valor de 0.0171**. En las escalas de asociación estadística, cualquier valor inferior a 0.10 se considera una relación nula o despreciable.

- **¿Cómo se traduce esto en el mundo real?** Estos resultados nos dicen que, en este grupo de 500 atletas, entrenar a máxima intensidad (*High*) no es el factor que está provocando que se lesionen más. Las lesiones ocurren en la misma proporción se entrene suave, moderado o fuerte. Esto es un hallazgo valioso para el proyecto, ya que nos obliga a buscar las verdaderas causas de las lesiones en otros bloques; probablemente estén más relacionadas con un descanso semanal insuficiente (`Recovery_Days_Per_Week`) o con picos críticos en los niveles de fatiga acumulada (`Fatigue_Score`), algo que analizaremos en las próximas secciones cruzadas.

4. Análisis descriptivo de variables binarias

En este cuarto bloque nos enfocamos en las variables dicotómicas del estudio: el Género (`Gender`) y el Indicador de Lesión (`Injury_Indicator`). Calcularemos sus tablas de frecuencias absolutas y relativas, y representaremos visualmente su distribución. Al contar con solo dos categorías por variable, utilizaremos gráficos de barras y sectores para analizar de forma directa la composición de la muestra respecto al sexo y la incidencia de lesiones.

4.a., 4.b. y 4.c. Proporciones, frecuencias y graficos de barras binarios

In [8]:

```python
# --------------------------------------------------------
# BLOQUE 4: CÁLCULOS Y GRÁFICOS DE VARIABLES BINARIAS
# --------------------------------------------------------

# Variables binarias definidas desde inicio
variables_bin = ['Gender', 'Injury_Indicator']

for col in variables_bin:
    print("\n" + "="*60)
    print(f" ANÁLISIS DE LA VARIABLE BINARIA: {col}")
    print("="*60)

    # 1. TABLA DE FRECUENCIAS (Absoluta y Porcentual)
    frec_absoluta = df_proyecto[col].value_counts()
    frec_relativa = df_proyecto[col].value_counts(normalize=True) * 100

    tabla_binarias = pd.DataFrame({
        'Número de Atletas (N)': frec_absoluta,
        'Porcentaje (%)': frec_relativa
    })
    print(tabla_binarias.round(2))
    print("\n")

    # 2. VISUALIZACIONES (Barras + Tarta)
    fig, axes = plt.subplots(1, 2, figsize=(14, 5))
    fig.suptitle(f'Distribución de Frecuencias: {col}', fontsize=14, fontweight='bold', y=1.02)

    # Gráfico de Barras actualizado sin advertencias
    sns.countplot(data=df_proyecto, x=col, ax=axes[0], order=frec_absoluta.index, hue=col, palette='Pastel1', edgecolor='black', legend=False)
    axes[0].set_title('Conteo de Atletas')
    axes[0].set_ylabel('Cantidad')

    # Gráfico de Sectores / Tarta
    axes[1].pie(frec_absoluta, labels=frec_absoluta.index, autopct='%1.1f%%', startangle=90,
             colors=sns.color_palette('Pastel1', len(frec_absoluta)), wedgeprops={'edgecolor': 'black'})
    axes[1].set_title('Proporción Porcentual')

    plt.tight_layout()
    plt.show()
    print("\n" + "-"*80)
```

```
============================================================
 ANÁLISIS DE LA VARIABLE BINARIA: Gender
============================================================
        Número de Atletas (N)  Porcentaje (%)
Gender
Male                      268            53.6
Female                    232            46.4
```

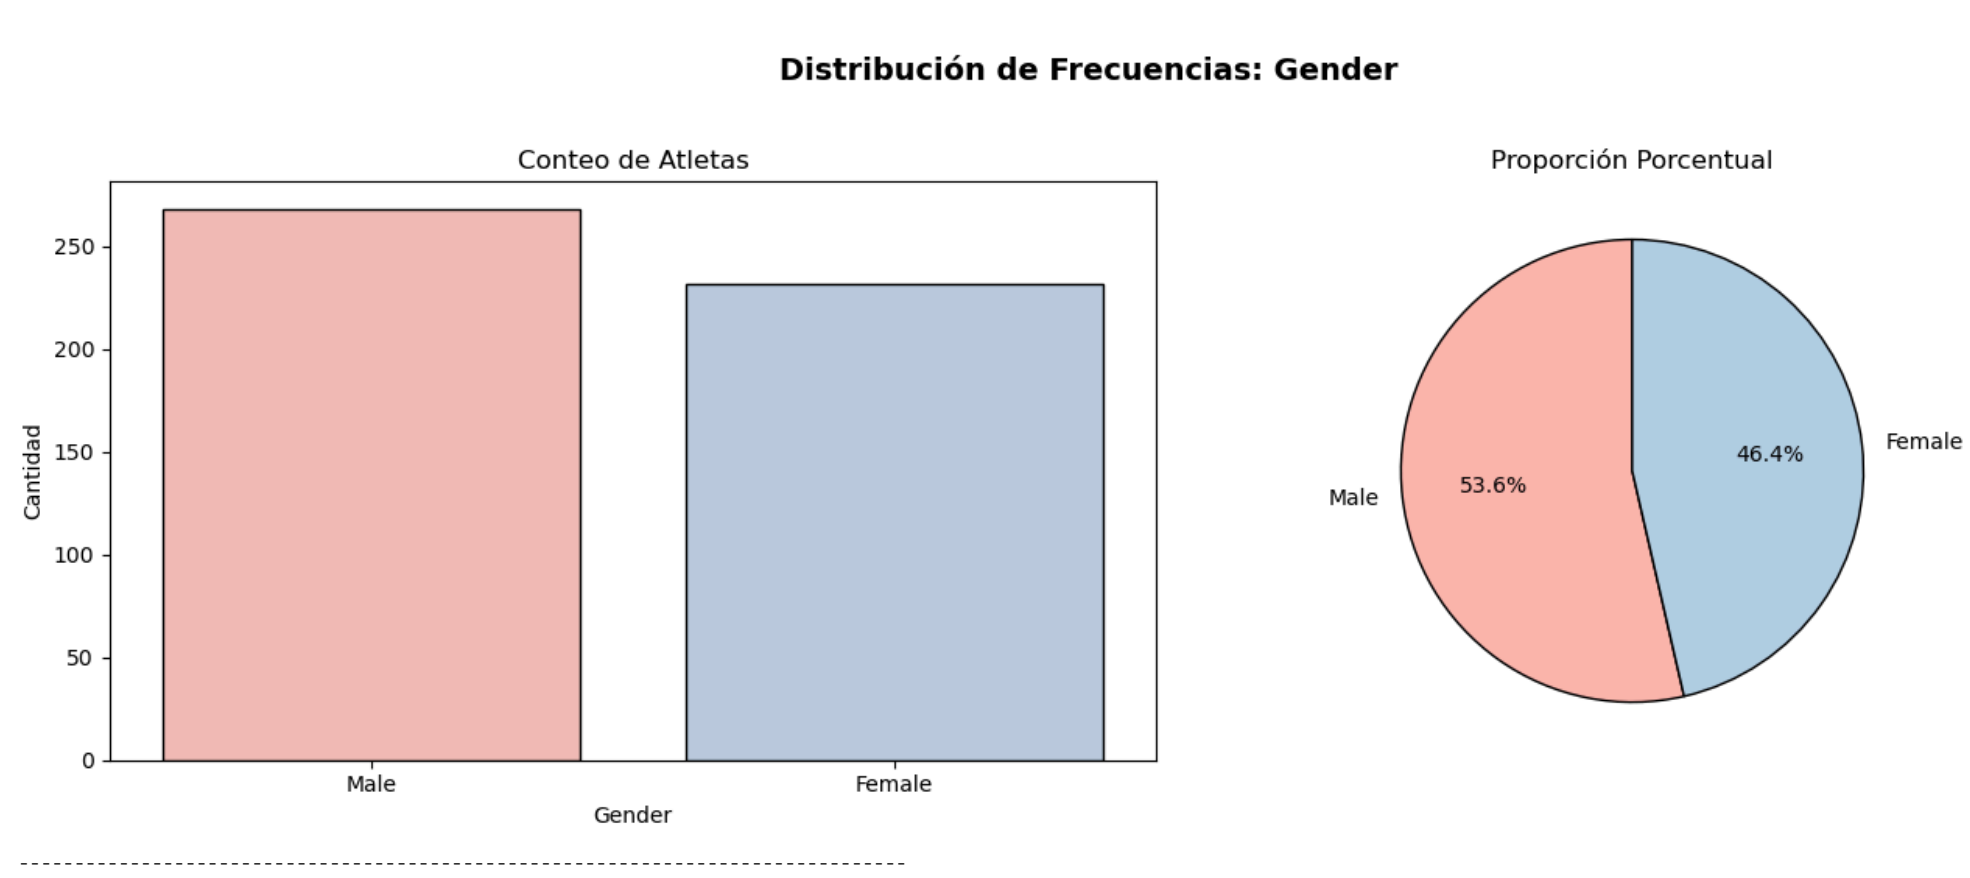

```
--------------------------------------------------------------------------------

============================================================
 ANÁLISIS DE LA VARIABLE BINARIA: Injury_Indicator
============================================================
                  Número de Atletas (N)  Porcentaje (%)
Injury_Indicator
Yes                                 256            51.2
No                                  244            48.8
```

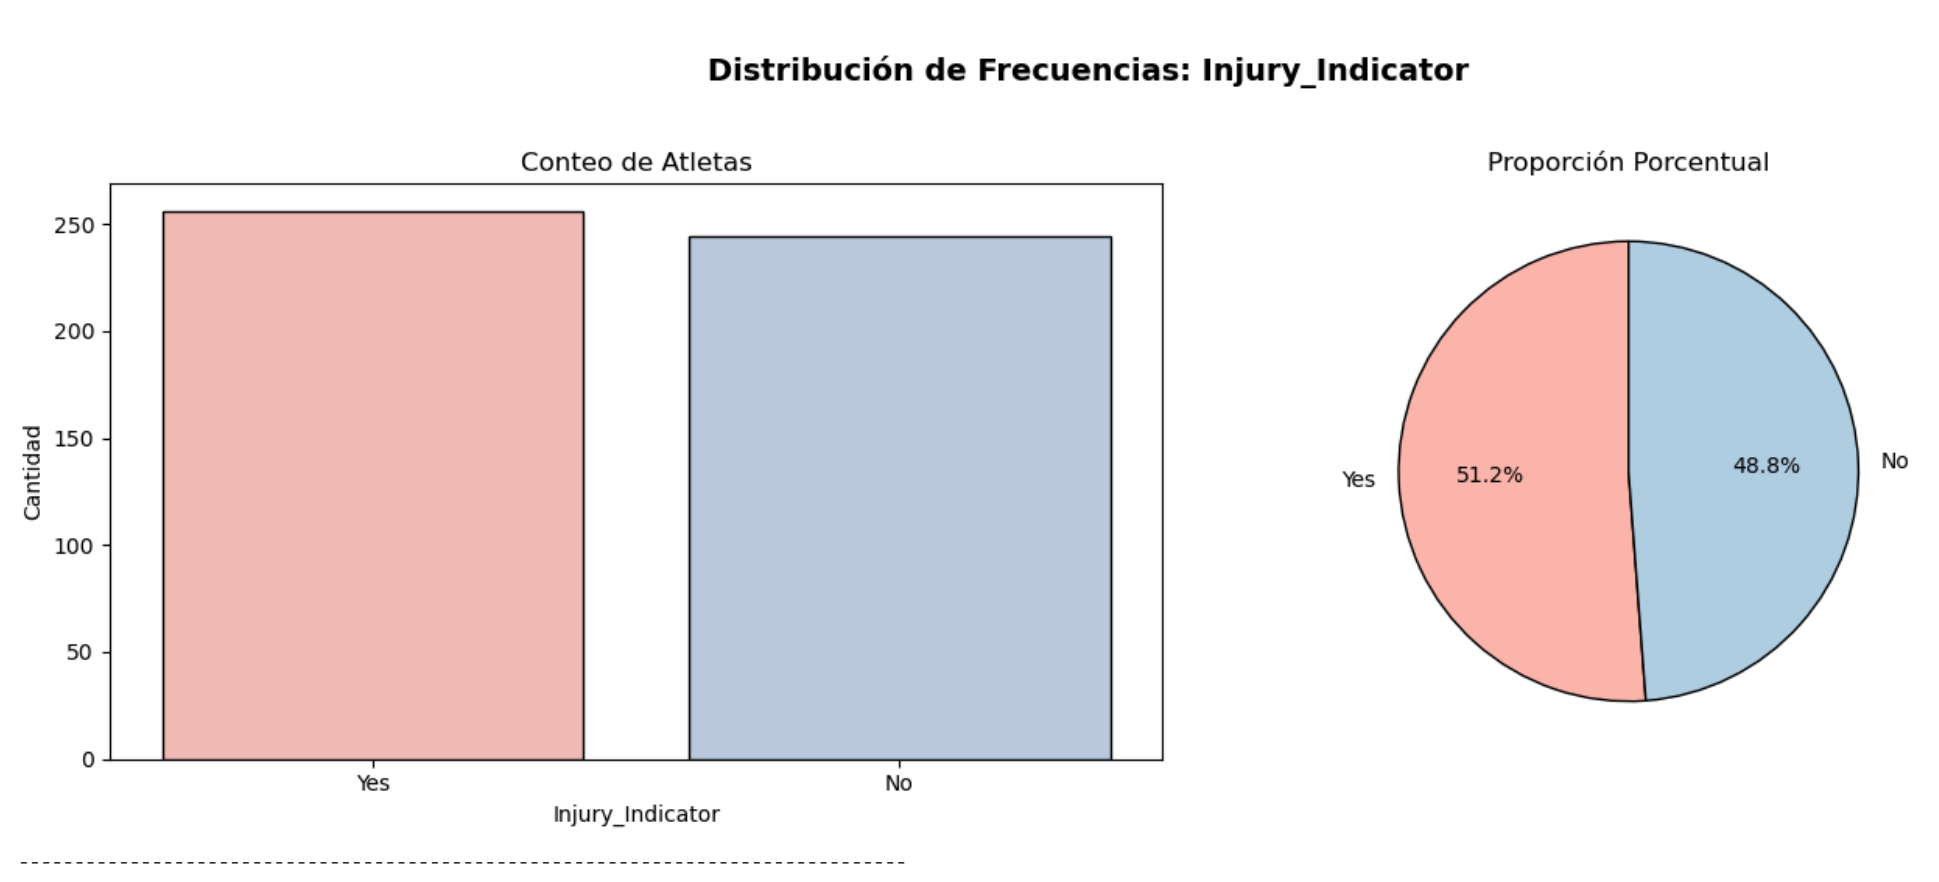

```
--------------------------------------------------------------------------------
```

4.d., 4.e. y 4.f. Analisis de relaciones binarias y contrastes de hipotesis

In [9]:

```python
import warnings
# Silenciamos advertencias estéticas
with warnings.catch_warnings():
    warnings.simplefilter("ignore")

    print("="*75)
    print("4.d. TABLA DE CONTINGENCIA BINARIA: Género vs Lesiones")
    print("="*75)
    # 1. Creamos la tabla cruzada entre las dos variables binarias
    tabla_binaria = pd.crosstab(df_proyecto['Gender'], df_proyecto['Injury_Indicator'])
    print("Tabla de contingencia real:")
    print(tabla_binaria)
    print("\n" + "-"*60)

    print("\n" + "="*75)
    print("4.e. COEFICIENTE DE CORRELACIÓN PHI (ϕ) Y SU MATRIZ")
    print("="*75)
    # 2. Convertimos temporalmente las variables a formato 0/1 numérico para calcular Phi (En variables dicotómicas, la correlación de Pearson equivale al coeficiente Phi)
    df_numerico_bin = pd.DataFrame({
        'Gender_Num': df_proyecto['Gender'].map({'Male': 1, 'Female': 0}),
        'Injury_Num': df_proyecto['Injury_Indicator'].map({'Yes': 1, 'No': 0})
    })

    matriz_phi = df_numerico_bin.corr(method='pearson')
    valor_phi = matriz_phi.iloc[0, 1]
    print(f"Coeficiente de Correlación Phi calculado: {valor_phi:.4f}")
    print("-"*60)

    # Dibujamos la matriz gráfica de correlación Phi
    plt.figure(figsize=(6, 4))
    sns.heatmap(matriz_phi, annot=True, cmap='coolwarm', vmin=-1, vmax=1, fmt=".4f", linewidths=0.5, linecolor='black')
    plt.title('4.e. Matriz Gráfica de Correlación Phi (ϕ)', fontsize=12, fontweight='bold', pad=15)
    plt.tight_layout()
    plt.show()

    print("\n" + "="*75)
    print("4.f. PRUEBA T-STUDENT: Comparación de Fatiga según Lesión")
    print("="*75)
    # 3. Separamos la puntuación de fatiga en dos grupos independientes: lesionados y sanos
    fatiga_sanos = df_proyecto[df_proyecto['Injury_Indicator'] == 'No']['Fatigue_Score'].dropna()
    fatiga_lesionados = df_proyecto[df_proyecto['Injury_Indicator'] == 'Yes']['Fatigue_Score'].dropna()

    # Calculamos las medias de cada grupo para analizarlas
    print(f"Media de Fatiga en Atletas Sanos:     {fatiga_sanos.mean():.2f}")
    print(f"Media de Fatiga en Atletas Lesionados: {fatiga_lesionados.mean():.2f}")
    print("-"*60)

    # Aplicamos el test t-Student de muestras independientes (asumiendo varianzas distintas / Welch t-test)
    t_stat, t_pval = stats.ttest_ind(fatiga_lesionados, fatiga_sanos, equal_var=False)
    print(f"Estadístico t de Student: {t_stat:.4f}")
    print(f"P-valor (p-value):        {t_pval:.4f}")
    print("="*75)
```

```
===========================================================================
4.d. TABLA DE CONTINGENCIA BINARIA: Género vs Lesiones
===========================================================================
Tabla de contingencia real:
Injury_Indicator   No  Yes
Gender
Female            106  126
Male              138  130

------------------------------------------------------------

===========================================================================
4.e. COEFICIENTE DE CORRELACIÓN PHI (ϕ) Y SU MATRIZ
===========================================================================
Coeficiente de Correlación Phi calculado: -0.0579
------------------------------------------------------------
```

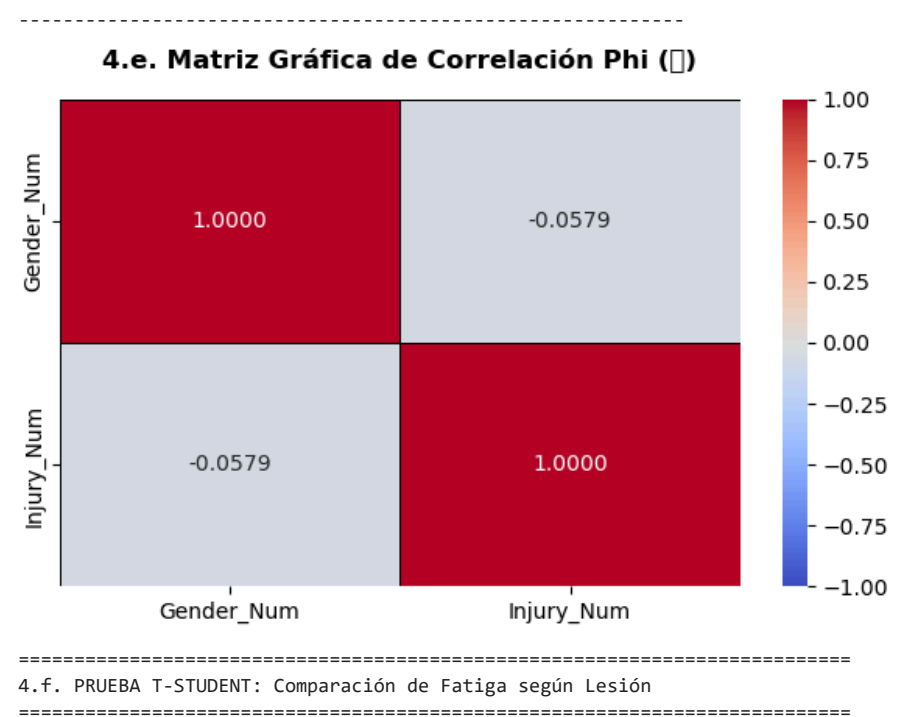

```
===========================================================================
4.f. PRUEBA T-STUDENT: Comparación de Fatiga según Lesión
===========================================================================
Media de Fatiga en Atletas Sanos:     5.00
Media de Fatiga en Atletas Lesionados: 4.92
------------------------------------------------------------
Estadístico t de Student: -0.3638
P-valor (p-value):        0.7161
===========================================================================
```

Interpretacion de los resultados del Bloque 4.

Tras analizar la distribución individual de las variables binarias y estudiar sus relaciones estadísticas mediante tablas cruzadas y contrastes de hipótesis, extraemos las siguientes conclusiones:

1. Perfil Individual de la Muestra (Análisis Univariante)

- **Distribución por Género (`Gender`):** La muestra presenta una composición muy equilibrada, contando con un **53.6%** de atletas masculinos (268 hombres) y un **46.4%** de atletas femeninas (232 mujeres). Esta proporción cercana al 50/50 garantiza que las comparaciones por sexo sean fiables y no estén sesgadas por tamaños de grupo desiguales.
- **Incidencia de Lesiones (`Injury_Indicator`):** Registramos una tasa de lesiones del **51.2%** (256 atletas lesionados) frente a un **48.8%** de atletas que se mantuvieron sanos (244 personas). Contar con un diseño equilibrado entre "casos" y "controles" es ideal para identificar con precisión qué factores diferencian a un atleta sano de uno lesionado en los modelos predictivos finales.

2. Relación entre Variables Binarias y Correlación Phi (`Gender` vs. `Injury_Indicator`)

Al cruzar el género con el indicador de lesiones, la tabla de contingencia muestra que 126 mujeres y 130 hombres sufrieron alguna lesión.

- Para medir la fuerza de esta relación, calculamos el **Coeficiente de Correlación Phi (ϕ)**, obteniendo un valor de **-0.0579**.
- **Interpretación:** En estadística, un coeficiente Phi tan cercano a cero indica una asociación lineal prácticamente inexistente. El signo negativo es irrelevante debido a su magnitud. Concluimos que el género del atleta no influye en absoluto en su probabilidad de lesionarse; hombres y mujeres se lesionan en la misma proporción dentro de este dataset.

3. Comparación de Grupos mediante la Prueba t-Student (`Injury_Indicator` vs. `Fatigue_Score`)

Para evaluar si el estado de salud del atleta está condicionado por el desgaste físico, comparamos estadísticamente las puntuaciones medias de fatiga entre el grupo de atletas sanos y el de lesionados bajo el siguiente planteamiento:

- **Hipótesis Nula (H_0):** No hay diferencia entre la media de fatiga de los atletas sanos y la de los lesionados ($\mu_{\text{sanos}} = \mu_{\text{lesionados}}$).
- **Hipótesis Alternativa (H_1):** Existe una diferencia significativa entre las medias de fatiga de ambos grupos.

Los datos muestran que la fatiga media en los atletas sanos es de **5.00**, mientras que en los lesionados es de **4.92**. Al aplicar la prueba t-Student para muestras independientes, obtenemos un estadístico $t = -0.3638$ y un **P-valor de 0.7161**.

- **Conclusión Estadística:** Dado que el p-valor es ampliamente superior al límite de significación estándar ($\alpha = 0.05$), **no podemos rechazar la hipótesis nula (H_0)**.
- **Significado Real:** No existe una diferencia estadísticamente significativa en los niveles de fatiga media entre los atletas que se lesionan y los que no. Este resultado, sumado al del bloque anterior, es clave: nos demuestra de forma matemática que analizar las variables de manera aislada o lineal no es suficiente para entender las lesiones de los deportistas. Esto justifica por qué deberíamos avanzar hacia modelos multivariantes más complejos (como el PCA y la Regresión Lineal) para encontrar los verdaderos patrones ocultos.

In [ ]: